机器学习纳米工程师毕业项目

猫狗大战

姓　　名：　吴典校

日　　期：　2018 年 02 月 27 日

目录

一、项目背景

猫狗大战是 Kaggle 上的一个关于在给定的图像中进行猫狗分类问题的分类问题，属于典型的图像识别问题。该项目所选择的数据集是 Kaggle 所提供的数据集，训练集是由 12500 张猫的图片和 12500 张狗的图片组成，测试集是由 12500 张未标记（labeled）的图片组成。

深度学习的思维范式是人工神经网络，需要追溯到二十世纪四十至流失纽带当时广为人知的控制论（cybernetics），所学的模型是最简单的线性加权，其应用领域极为受限，最为著名的是不能成立“异或”问题。

直到 80 年代，David Rumelhar 和 Geoffery E. Hinton 等人提出了反向传播算法，解决了两层神经网络所需要的复杂计算量问题，同时解决了单层神经网络无法处理“异或问题”，但受限于数据获取的瓶颈，只能在中小规模数据上训练，且过拟合极大困扰着神经网络算法。

随着软件算法和硬件性能的不断优化，直到 2006 年，Geoffery E. Hinton 等发表文章提出一种称为“深度置信网络”（deep belief network）的神经网络模型可通过逐层预训练的方式有效完成模型训练过程。

得益于软件算法、数据量剧增和硬件配置的发展，图像识别在静态平面图片识别上已十分成熟，但对于空间几何识别仍需要更多开发人员进行研究和开发，最终运用到实际运用中，对人类的发展产生深远的影响。

二、问题陈述

猫狗大战要解决的根本问题是图像分类，其中由于图片的分辨率差异大，尺寸大小不一，同时猫狗的种类众多，颜色各异，背景环境不同，因此该数据集的复杂程度亦增加了模型搭建的难度。

解决图像识别问题存在以下方法：KNN、SVM、BP 神经网络、CNN 和迁移学习，为了得到性能更优的模型，本项目仅讨论 CNN 与迁移学习。

三、数据或输入

3.1 数据描述及可视化

该项目所选择的数据集是 Kaggle 所提供的数据集，训练集是由已标记（labeled）的 12500 张猫的图片和 12500 张狗的图片组成，测试集是由 12500 张未标记（Not labeled）的图片组成。

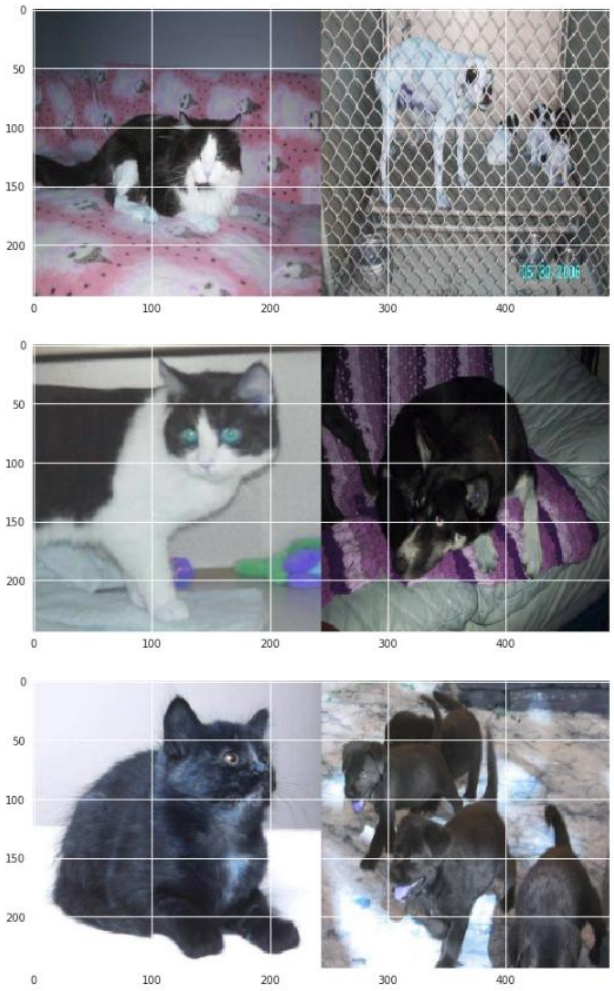

同时对数据异常值进行监测，通过对图片三个维度数值的乘积进行分析，得到其分布图，即一个正态分布图：

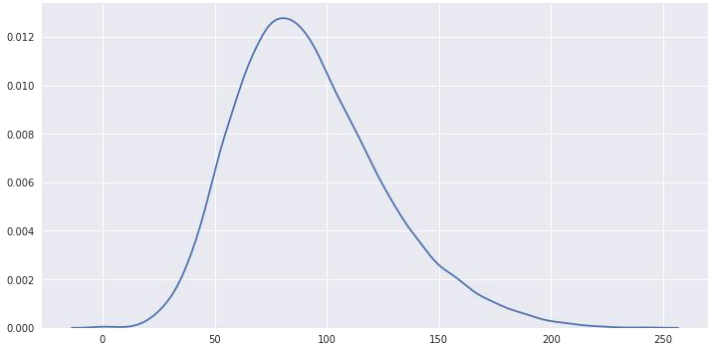

显示值小于 10 以及大于 235 的图片，其图片如下。可以看出该训练集中仍存在部分异常值。

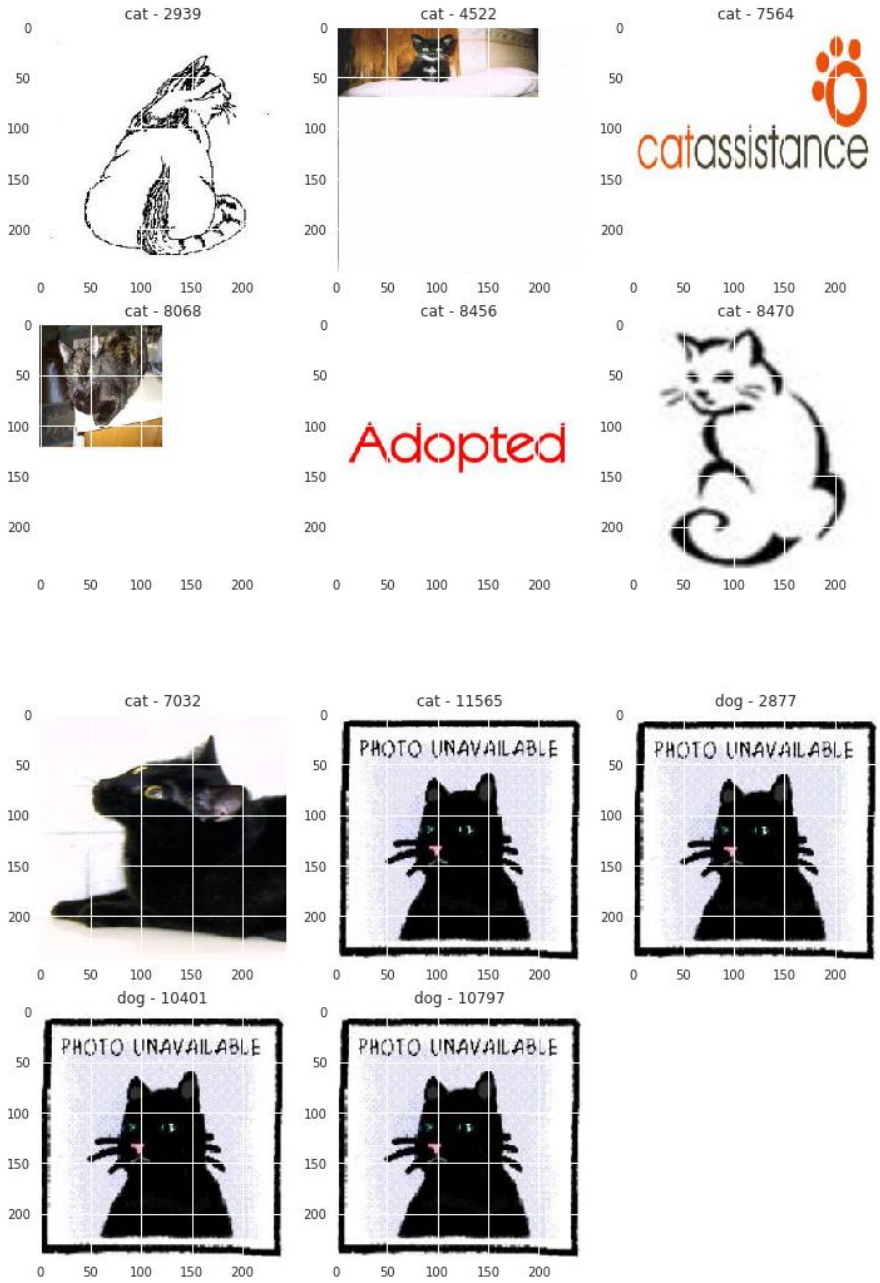

3.2 数据预处理

首先使用 Opencv 库中的 imread()函数读取训练集数据和测试集数据，由于基于现有模型进行计算，每种模型在读取数据时应满足固定的分辨率要求，如 Xception 和 InceptionV3 模型要求的输入分辨率为 299×299，ResNet、DenseNet 模型要求的输入分辨率为 244×244。为了保证缩放后的图片不会出现严重变形或者是细节丢失的情况，为此使用 resize 函数将照片缩放到模型所要求的输入尺寸。。

同时，为了保证训练过程中调节参数，将原始训练数据拆分为照片总量为 20000 张的训练集，总量为 5000 张（猫狗图像各 2500 张）作为验证集。由于验证集仅是用来调节模型中的超参数，因此总量为 5000 张的验证集足以将模型参数调整至最佳。同时在分割训练集和验证集时使用 Shuffle

属性，将数据集打乱，防止分割时猫狗分布不均。

四、评估指标

对于分类问题，由于在 CNN 模型和迁移模型中都使用梯度下降的实现方法，即通过求评估函数的梯度以不断更新神经网络中的权值，但在求梯度下降最优解时，必须保证评估函数为凸函数，故使用 Loss Function，也称为 cross-entropy 检测算法运行情况，公式如下：

$$L(\hat{y}, y) = -(y \cdot \log(\hat{y}) + (1 - y) \cdot \log(1 - \hat{y}))$$

其中，y 为测试集中的 y 值，$\hat{y}$ 为模型所预测的 y 值。

对运用于更新权重 w、偏差 b 的模型中，使用的评估函数为：

$$J(w,b) = -\frac{1}{m} \cdot \sum_{i=1}^{m} (y^{[i]} \cdot \log(\widehat{y^{[i]}}) + (1 - y^{[i]}) \cdot \log(1 - \widehat{y^{[i]}}))$$

其中，$y^{[i]}$ 为测试集中第 i 条数据的 y 值，$\widehat{y^{[i]}}$ 为第 i 条数据的预测值，m 为测试集数据总个数。

五、解决方法描述

CNN 卷积神经网络是一种层次模型，其基本结构为输入原始数据-卷积操作-汇合（pooling）操作-非线性激活函数（ReLU）映射、分类（Classification）等一系列操作的层层堆叠，其核心是通过使用共享权重的卷积层替代了一般的全连接层。

迁移学习则是将已经训练的卷积神经网络模型迁移到其他数量集，以节省训练时间。现阶段对于 ImageNet 数据已经存在诸多预训练模型，本项目中使用 ResNet50、InceptionV3、Xception 和 Inception Resnet v2 等四个模型进行训练。

迁移学习有两种策略，一是微调（fine-tuning）,即训练已有神经网络中的所有层；二是冻结和训练（freeze and train），即将前面一定数量的层冻结后对其他层进行微调，一般情况下只训练最后一层。本项目中猫狗数据集与 ImageNet 接近，使用微调或者冻结均可，故在本项目中同时使用该两种方法并进行对比。

以下对 ResNet50、InceptionV3、Xception 和 Inception Resnet v2 五个模型进行简单的介绍：

5.1 ResNet50

ResNet50 模型是 2015 年 ILSVRC & COCO competitions 的 ImageNet Detection, ImageNet localization, COCO detection 以及 COCO segmentation 项目中获得第一名的模型。该模型是由微软的

Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun 所提出。解决了更深的模型反而比更浅的模型效果更差的问题。

其主要改变是原来深度神经网络的基础上，对于两层以上的 block 块，增加 shortcut connection，即是 y=x，形成一个 block，可以防止在参数传递过程中，若出现权重为零，会把输入值置零的情况，其 Block 块如下图所示。

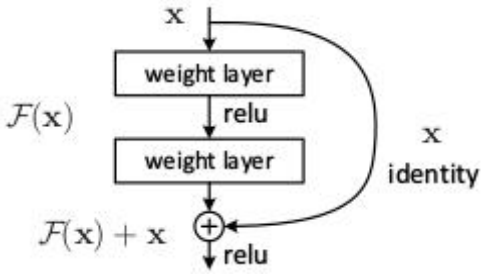

以上模块有两层 Relu 非线性函数层，首层表达式为：

$$\mathcal{F} = W_2\sigma(W_1\mathbf{x})$$

第二层加入 shortcut，获得输出：

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{W_i\}) + \mathbf{x}.$$

在对 CIFAR-10 数据集测试中，其测试图如下：

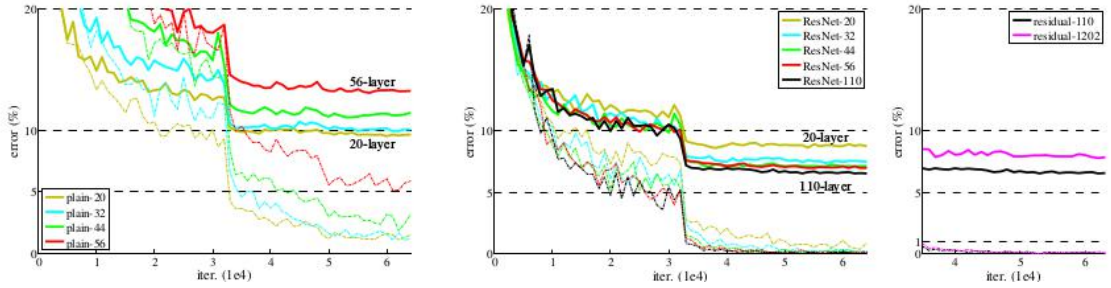

其中左边是传统神经网络是模型，可以看出 56-layers 的模型是比 20-layers 的模型训练效果更差。中间 ResNet 模型训练结果，可以看出层数原告，其训练效果更好，而且普遍比传统神经网络的训练效果好。右图是层数为 110 和 1202 的 ResNet 模型，其中 110-layers-ResNet 模型是比 1202 的 ResNet 模型训练效果要好。

5.2 InceptionV3

InceptionV3 是 2015 年由 Google 团队提出的改进模型，在原有 Inception 模型上进行优化，进一步减少计算成本。原有的 Inception 网络模型结构的基础模块如下所示：

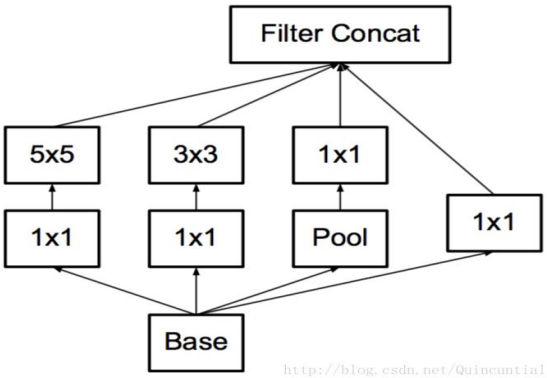

Inception 网络模型中的基础模块是将 1 × 1 ，3 × 3 ，5 × 5 的卷基层和 Pooling layer 堆叠在一起，增加了网络的宽度以及对尺度的适应性。

然而，5×5 卷积核所需的计算量太大，故 Inception 网络模型将 5×5 卷积核由两个 3×3 卷积核替换，可减少计算成本是全卷积的，每个权重对应每个激活的乘法，降低计算成本会导致参数量降低，从而加快训练，

为了进一步简化 3×3 卷积层序列，可以通过使用非对称个卷积，即 n×1。例如使用 3×1 卷积后接一个 1×3 卷积，其效果相当于 3×3 卷积核。其网络结构如下：

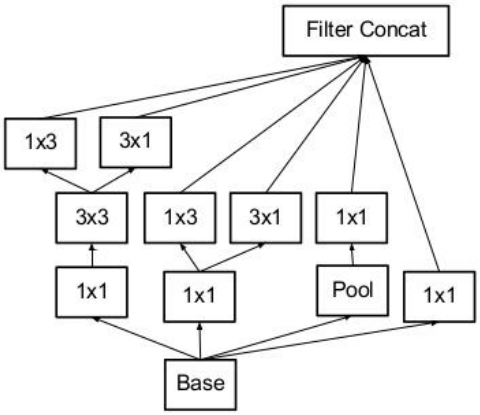

对于输入和 Fliters 数量相等，对于相同数量的输出 Fliters，该方案可以便宜 33%。理论上，可以通过 1×n 卷积后接一个 n×1 卷积，且随着 n 增长，计算成本节省显著增加。但实际上该分解在靠前的层工作效果不佳，但是到中等网络尺寸 m∈（12,20），其效果非常好。对于在 17×17 网络中，可以选择 n=7。

通过在 ILSVRC-2012 验证集上进行评估，测试结果如下所示。可以看出该模型是比传统深度神经网络模型处理的效果会更好。

Network	Models Evaluated	Crops Evaluated	Top-1 Error	Top-5 Error
VGGNet [18]	2	-	23.7%	6.8%
GoogLeNet [20]	7	144	-	6.67%
PReLU [6]	-	-	-	4.94%
BN-Inception [7]	6	144	20.1%	4.9%
Inception-v3	4	144	**17.2%**	**3.58%** *

5.3 InceptionResNetV2

InceptionResNetV2 模型是 2016 年 Google 对 Inception V3 模型的另一种改进，即是在 Inception V3 模型上增加一个 shortcut，其模型结构如下所示。其模型深度比 Inception V3 模型更深，同时重复的残差区块被压缩简化，即包含更少的并行塔（Parallel towers）

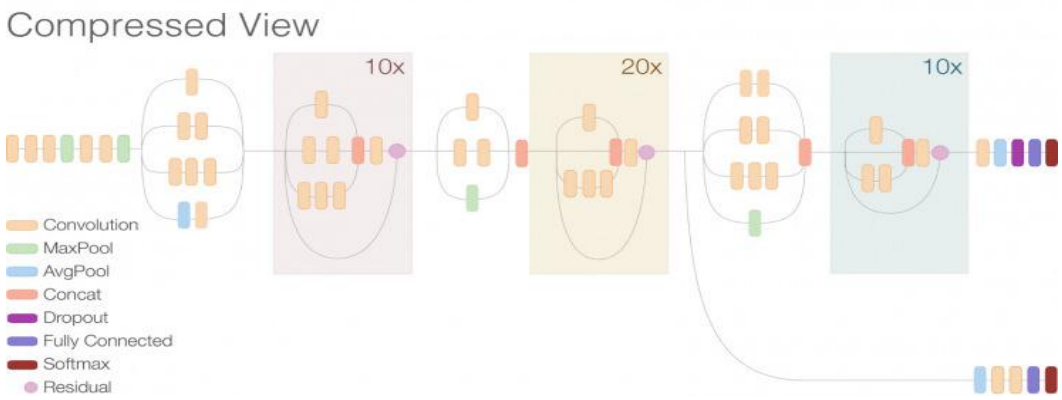

通过在 ILSVRC-2012 验证集上进行评估，其训练结果亦优于 Inception V3 以及 ResNet151，其测试结果如下所示：。

Network	Crops	Top-1 Error	Top-5 Error
ResNet-151 [5]	10	21.4%	5.7%
Inception-v3 [15]	12	19.8%	4.6%
Inception-ResNet-v1	12	19.8%	4.6%
Inception-v4	12	18.7%	4.2%
Inception-ResNet-v2	12	18.7%	4.1%

5.4 Xception

Xception 模型是谷歌对 Inception V3 模型的另一种改进。Inception V3 模型通过对 1×1、3×3、5×5 和 Pooling 结构，以更少的参数和更少的计算成本以学习更丰富的特征。Inception 模块首先用 1×1 的卷积核将特征图每个通道映射到新的空间，连接各个通道；再通过 3×3、5×5 卷积核进行卷积，连

接各层权重和各个通道。但此时各层权重的连接和各个通道的连接并没有完全分离，若将其权重连接性和通道连接性完全分离开，效果会不会更为出色。基于该考虑，Xception 尝试将所有 3×3、5×5 卷积核都作用在只有一个通道的特征图上。其结构如下：

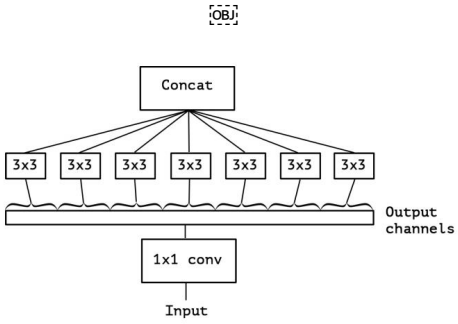

该模型是通过多个 3×3 卷积核拼接，使其与 1×1 卷积核输出通道相等，此时每个 3×3 卷积核仅作用于包含一个通道的特征图上，即 Extream Inception 模块。其完整网络结构，如下图所示。

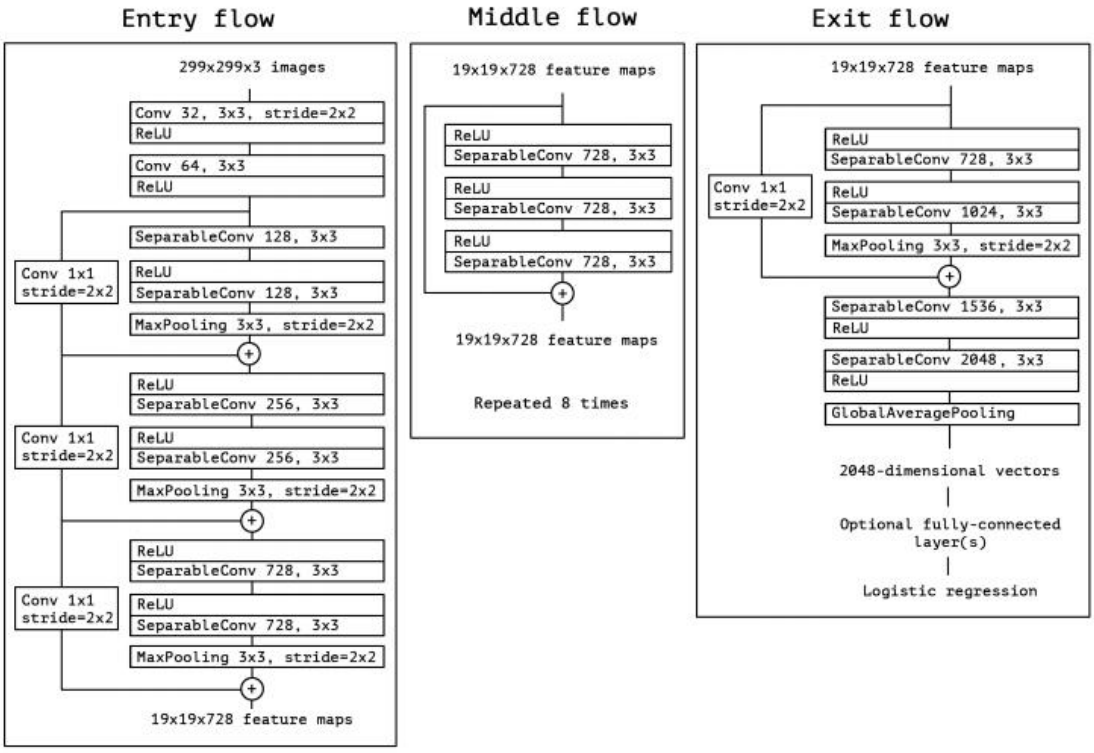

分别在 ImageNet 和 JFT 上进行训练，并分别在 ImageNet 和 FastEval14k 上进行测试，其结果如下所示。可以看出 Xception 的效果相比于 Inception V3 有所上升。

	Top-1 accuracy	Top-5 accuracy
VGG-16	0.715	0.901
ResNet-152	0.770	0.933
Inception V3	0.782	0.941
Xception	**0.790**	**0.945**

六、基准模型

Kaggle 上 Public Leaderboard 是对测试集数据进行评估，评估函数为 Log Loss 函数，本项目基准模型目标是，测试集的分类结果可以排在 Public Leaderboard 上的前 100 名，即 Log loss 小于 0.05629。

七、项目设计

7.1 数据预处理

首先使用 Opencv 库中的 imread()函数读取训练集数据和测试集数据，由于基于现有模型进行计算，每种模型在读取数据时应满足固定的分辨率要求，如 Xception 和 InceptionV3 模型要求的输入分辨率为 299×299，ResNet、DenseNet 模型要求的输入分辨率为 244×244。为了保证缩放后的图片不会出现严重变形或者是细节丢失的情况，为此使用 resize 函数将照片缩放到模型所要求的输入尺寸。

同时，为了保证训练过程中调节参数，将原始训练数据拆分为照片总量为 20000 张的训练集，总量为 5000 张（猫狗图像各 2500 张）作为验证集。由于验证集仅是用来调节模型中的超参数，因此总量为 5000 张的验证集足以将模型参数调整至最佳。同时在分割训练集和验证集时使用 Shuffle 属性，将数据集打乱，防止分割时猫狗分布不均。

在生成模型时，使用 Lambda 层引用模型中的 preprocess_input 模块对载入模型的 Tensor 进行预处理，其中每种模型的 preprocess_input 的作用不一样，如 ResNet50 模型的 preprocess_input 是将 RGB 每个色彩通道减去 ImageNet 数据集相应通道的均值（103.939, 116.779, 123.68）， 并将每个色彩通道从 RGB 调整为 BGR；而 InceptionV3 和 Xception 模型 preprocess_input 是将数据从（0, 255）缩放到（-1,1）区间内。如 Resnet50 模型数据预处理代码如下所示。

```
input_x = Input((244,244,3))
input_x = Lambda(resnet50.preprocess_input)(input_y)
base_model_VGG = resnet50.Resnet50(weights = 'imagenet', include_top = False, input_tensor
= input_x)
```

7.2 模型训练

利用 Xception、InceptionV3、 ResNet50、DenseNet121 模型进行建模，用 sigmoid 激活函数的

层替代原有的的最后一层。同时在训练过程中引入 Early Stopping 以避免过拟合，在 val_loss 连续 5 个 epochs 没有优化时停止训练。训练环境是在 Google Platform 上进行训练，使用的显卡是 NVIDIA Tesla P100。

7.2.1 ResNet50

设定其超参数值如下：

Epochs	Batch_size	Optimizer	Dropout	锁层
15	256	adam	0.4	True

其训练结果如下：

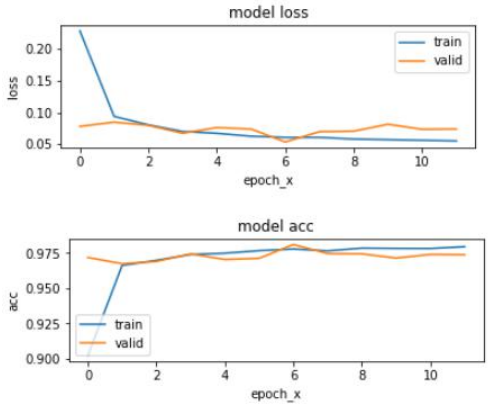

ResNet50 模型对测试集进行预测，并将结果上传至 Kaggle，获得得分为 0.08847。

7.2.2 InceptionV3

设定其超参数值如下：

Epochs	Batch_size	Optimizer	Dropout	锁层
20	64	Sgd(lr=0.001,momentum=,0.9decay = 1e-3)	0.5	False

其训练结果可视化如下：

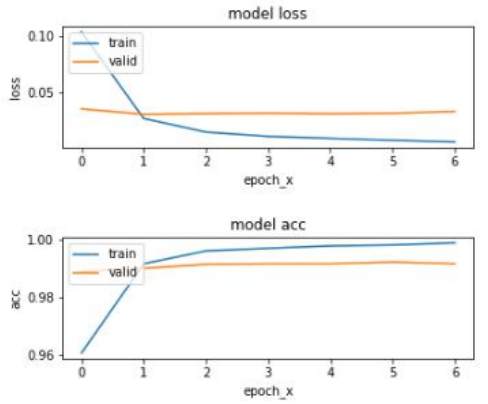

InceptionV3 模型对测试集进行预测，并将结果上传至 Kaggle，获得得分为 0.04359。

7.2.3 Xception

设定其超参数值如下：

Epochs	Batch_size	Optimizer	Dropout	锁层
10	32	Sgd(lr=0.001,momentum=,0.9decay = 1e-3)	0.5	False

其训练结果可视化如下：

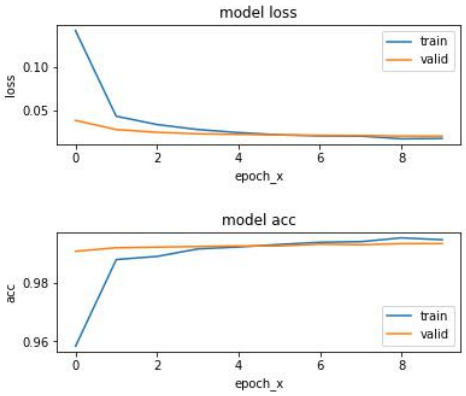

Xception 模型对测试集进行预测，并将结果上传至 Kaggle，获得得分为 0.04151。

7.2.4 Inception_Resnet_v2

设定其超参数值如下：

Epochs	Batch_size	Optimizer	Dropout	锁层
20	32	Sgd(lr=0.001,decay = 1e-3)	0.5	False

其训练结果可视化如下：

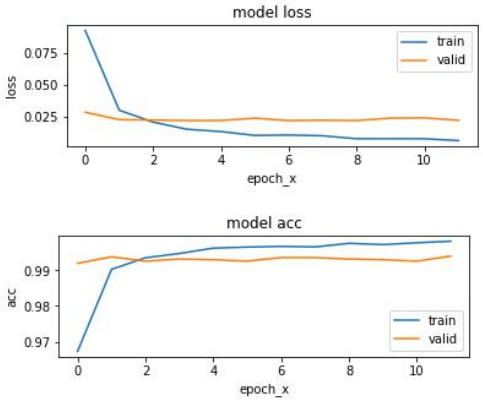

模型对测试集进行预测，并将结果上传至 Kaggle，获得得分为 0.03942。

同时对每种模型的对数损失得分进行分析，得到三个得分最高的模型，并提取该三个模型的特征进行融合，得到最优化模型。

7.3 模型改进

由上可知，InceptionV3、Xception 和 Inception_Resnet_v2 三个模型得分最高，提取该三个测试集特征进行堆叠，获得融合后的特征集合。

设定其超参数值如下：

Epochs	Batch_size	Optimizer	Dropout	锁层
20	64	Sgd(lr=0.001,decay = 1e-3)	0.5	False

其训练结果可视化如下：

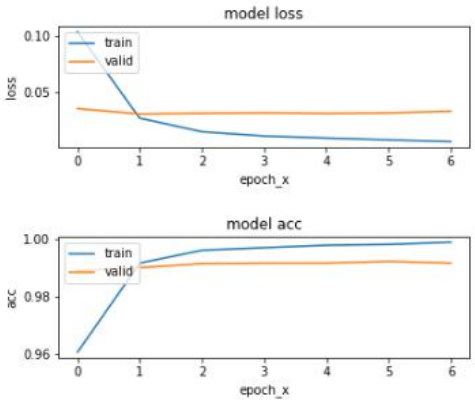

模型对测试集进行预测，并将结果上传至 Kaggle，获得得分为 0.03982。

八、结果分析

从 Inception、ResNet50、Xception 和 Inception_Resnet_v2 训练结果上看，Inception_Resnet_v2 的对测试集的得分是最高的，甚至高于 Inception、Xception 和 Inception_Resnet_v2 融合模型的得分。

进行可视化识别出未能成功预测的图片，即查看对测试集的概率值小于 0.53 以及大于 0.47 的图片。其图片如下所示：

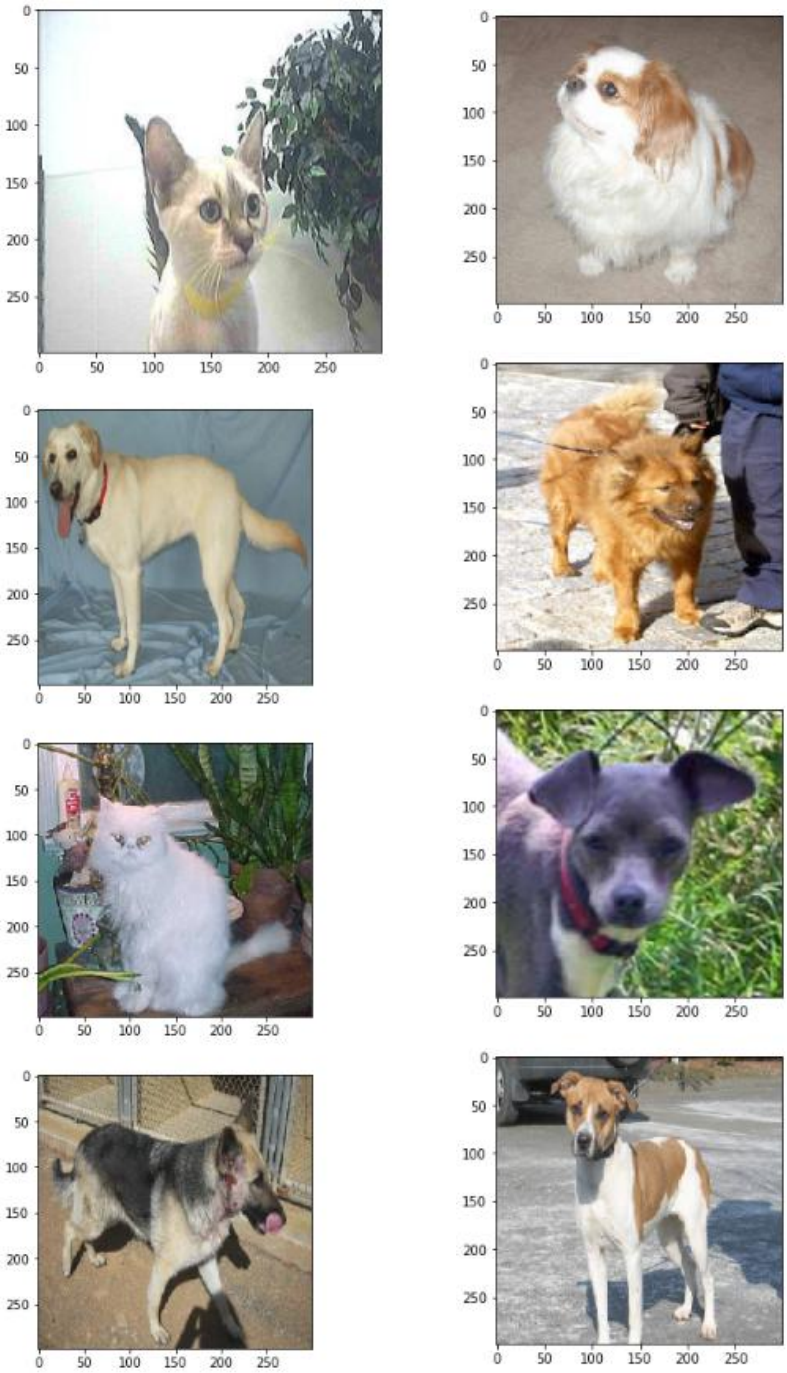

虽然该模型可以判断出图片是狗还是猫，但是模型并不确定，其中概率在 0.4 到 0.6 之间的测试图片共有 33 张，若可以发现不确定该 33 张图片为何无法肯定的原因，应该会让自己对神经网络模型更加熟悉。通过这个项目，我从自己安装 Ubuntu 系统，到配置深度学习环境（CUDA 和 Cudnn），再到搭建谷歌云服务器，其过程虽痛苦，但最后实现的那一刻真心感到兴奋，非常感谢。

九、主要参考文献

[1] Andrew Ng, Deep Learning.ai, Coursera

[2] Kaiming He, Xiangyu Zhang, Shaoqing Ren, Jian Sun. Deep Residual Learning for image recognition, arXiv:1512.03385v1

[3] Gao Huang, Zhuang Liu, Laurens van der Maaten. Densely Connected Convolutional Networks, arXiv:1608.06993v5

[4] Christian Szegedy, Vincent Vanhoucke, Sergey Ioffe, Jonathon Shlens. Rethinking the Inception Architecture for Computer Vision,arXiv:1512.00567v3

[5] Francois Chollet. Xception Deep Learning with Depthwise Separable Convolutions, arXiv:1610.02357v3

[6] Christian Szegedy, Sergey Ioffe, Vincent Vanhoucke, Alex Alemi. Inception-v4, Inception-ResNet and the Impact of Residual Connections on Learning, arXiv:1602.07261